哈尔滨工业大学

<<模式识别与深度学习>>

实验一报告

(2022 年度春季学期)

姓名:	姚舜宇
学号:	**1190202107**
学院:	计算学部
教师:	金野

基于 ViT 的半监督语义信息标注方法

一、课题来源及研究目的

我们提出了一种针对语义分割数据集的半监督的数据标注方法，对于语义分割数据集中的每一类事物训练一个十分轻量的分类器，仅需依赖少量的人工标注数据，即可获取类别中剩余数据较为精确的语义标注信息。

数据集的获取是机器学习中至关重要的一环。再优秀的理论模型，没有优质数据的加持，终归只是空中楼阁。随着深度学习的发展与壮大，训练所需数据量的规模也在急速增长。然而对于大多数的完备监督学习方法来说，数据集不仅仅需要量，还需注重质。准确、精确的数据集标注对于监督学习方法来说至关重要，而获取准确、精确的标注信息，往往仍需要借助人类的力量。以当下数据集的规模而言，人工标注完整的数据集绝非易事，让人重复的标注成千上万的信息，需要耗费大量人力、物力、精力。

因此，如果找到一种方法可以仅依赖较少量的标注信息，去产生剩余的所有标注信息，那么对于数据集的制作获取将有积极意义。本文就图像语义分割数据集提出了一种半监督的语义信息标注方法，可以使用仅 20 张左右具有人工标注语义信息的图片，来获取整个类别剩余数据的语义标注信息，标注的精确度可以达到较高水平。

二、相关研究现状

1. 语义特征提取

深度学习在语义分割任务中的应用最早来源于全卷积网络（FCN），利用卷积提取语义特征信息并实现语义分割。后续空洞卷积、特征金字塔等的提出，进一步提升了基于卷积特征的语义分割的性能。

自注意力机制与 Transformer 模型为深度学习带来了新的思路。自注意力机制最初被应用于自然语言处理领域，并取得了卓越的效果，随后谷歌团队将 Transformer 结构巧妙的移植于 cv 领域，提出 vision Transformer（ViT），在经典的图像分类任务上超越了 CNN 的性能。ViT 对于视觉特征的提取和理解同样值得玩味。最近已有研究团队发现，ViT 提取的 patch 特征具有丰富的语义内涵，借助无监督聚类方法，可以将多张图像放在一起无监督的学习出图像的潜在语义特征。基于这点，我们同样采用 ViT 作为图像的语义特征提取工具。

2. 数据集生成模型

生成对抗网络[1]（GAN）是一种极为强大的生成式模型，随着 StyleGAN 等高质量生成器的出现，生成高分辨率、极为真实的图像成为可能。人们开始使用

这些高质量的生成器来生成图片数据集，并且将这些合成的数据集用于训练计算机视觉模型。

去年，来自英伟达的研究团队提出了 datasetGAN，这是一种合成带有语义分割标注信息数据集的生成式模型，模型思路简单却高效。他们将 StyleGAN 生成器中各上采样层提取的特征调整到相同大小并拼接，拼接得到逐像素的特征序列，这些逐像素特征依次送入一个预训练的 3 层 MLP 分类器，即可获得每一像素的语义分类。MLP 的训练采用半监督的方式，仅需 16 张人工标注的图像。我们的语义标注方法将参考这一半监督思路。

三、主要研究内容

我们将从数据集某一类图像中挑选出 20 张左右，使用 DINO-ViT 这一自监督训练的 Transformer 模型提取图像的多尺度特征，之后参考 datasetGAN 的方式将多尺度特征进行拼接整合，然后训练一个 MLP 分类器来对逐 patch 的特征进行分类，从而达到半监督产生语义标注信息的目的，其中的人工成本仅为 20 张左右的语义信息标注。

DatasetGAN 在人脸数据上合成图像、产生标注信息的真实度、准确度达到了很高的水平。但是由于 StyleGAN 是一种强大的结构化生成器，一个预训练的 StyleGAN 生成器往往只能生成某一类结构化的数据，而如果对于多种类的数据，如需合成人脸、汽车、狗三种事物的数据集，将需要 3 个预训练的 StyleGAN 生成器。StyleGAN 生成器的训练是一个耗时的过程，对于非结构化的数据集，如 ImageNet，合成将变得不现实。而有时，图像本身不需合成，已有很多现有的非结构化数据集，我们仅需其上的语义标注信息。

因此，我们对于一个给定的丰富的非结构化数据集，参考 datasetGAN 中的简单半监督分类方法，利用 ViT 提取的特征信息，实现对非结构化数据集语义标注信息的生成。

与 CNN 相比，ViT 模型有着感受野更大、深度特征不失真的特点。ViT 的深度特征包含了更具细粒度的语义信息、有着更高的分辨率。另外，已有研究证实，使用自监督方法通过知识蒸馏训练出的 DINO-ViT 在图像的深度视觉特征方面与全监督 ViT 相比反而有诸多优势，DINO-ViT 特征具有类似于语义对象部分的局部语义信息，全监督 ViT 特征强调全局类信息，反而不适用于语义信息的获取。因此综合来说，自监督的 DINO-ViT 模型最适合用来提取深层的语义特征，可以将其作为一种密集的视觉描述符。

此外，datasetGAN 的半监督语义分类思路从实验结果看出是非常行之有效的。其利用卷积提取的特征，便可达到了非常优秀的准确率，那么我们换用更有效的 ViT 特征仍可达到这一水平。

四、实施方案

项目流程图：

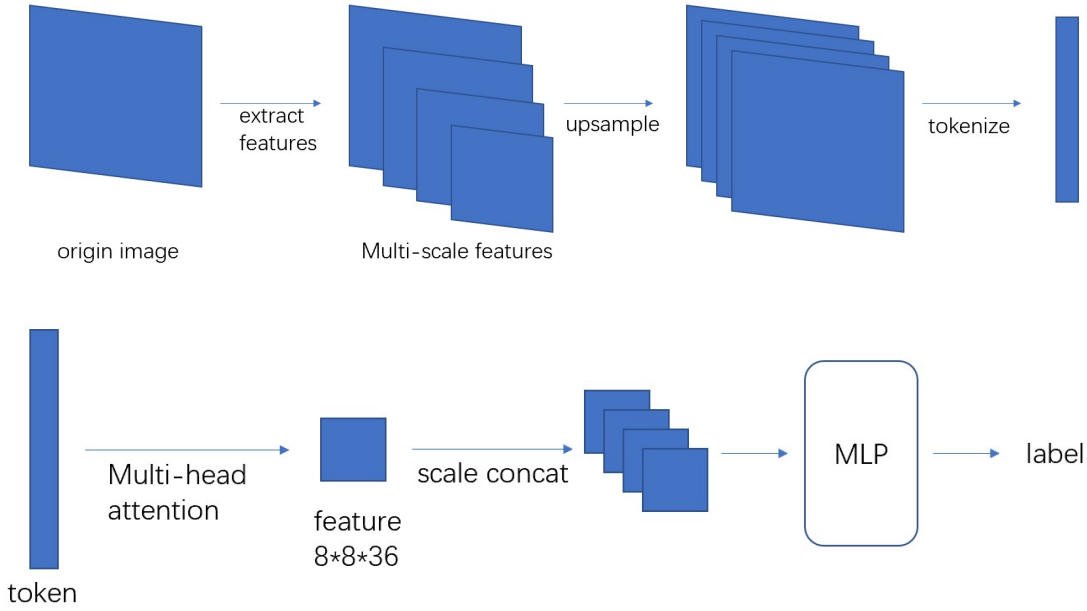

整个过程中，我主要承担了训练的工作，包括使用预训练的 DINO 提取多尺度特征，为各个类别训练一个 MLP 用于生成标签。

我们获取了 DINO-ViT 的预训练模型用于特征提取。数据集将采用 COCO2017 和 PartImageNet。

COCO 数据集不提供实体的具体语义标注信息，所以我们将对 COCO 数据集中选定的目标实体种类进行裁剪，手工标注 20 张左右的图片。PartImageNet 数据集来源于 ImageNet 数据集，包含了超过 100 类图片，并提供了语义标注信息，因此我们直接选取 20 张左右标注信息使用即可。

然后，利用 DINO-ViT 预训练模型，对选取的 20 张图像进行特征提取，然后拼接整合成逐 patch 的特征块，将这些逐 patch 特征送入 3 层 MLP 训练一个分类器。那么对于每一类图片，都有一个这样的 MLP 分类器。最后我们将在 PartImageNet 上进行准确性测试。

下面详细介绍我所承担的工作。

DINO-ViT 继承了 ViT 的典型结构，通过知识蒸馏实现无监督训练。DINO 中一个 Transformer Block 的结构如下：

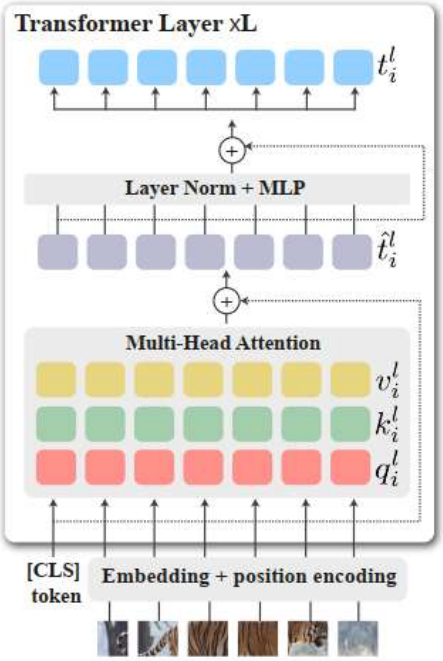

将图像分割成一个个互不重叠的 patch，并考虑到图像的语义相关性，加入位置编码后，对于每个 patch 变换计算 q、k、v 三属性向量，得到输出结果 $Z=SoftMax(QK^T)V$，其中 $SoftMax(QK^T)$即计算了不同 patch 所占的注意力权重，结果为每个 patch 之间的相似度矩阵。上述的一种由 patch 转变 Z 的变换将 patch 转换嵌入了一种表征空间，称为单头注意力，那么将 patch 嵌入多个并列的表征空间，然后拼接在一起，称为多头注意力(Multi-Head Attention)。获取加权后的特征向量 Z 后，将其进行 layer norm 并送入 MLP 做前馈变换，得到一层 Transformer 块的输出特征。

DINO 中共堆叠 11 层 Transformer 块，多头注意力中的头数为 6。值得注意的是，Transformer 块的结构决定了经过多层提取后，特征的维度和尺度与最初输入的 patch 相同，特征维度不会随着层数加深而减小。

典型的 ViT 结构中，patch 是互不重叠的，但是本实验中为了提高特征图的分辨率，我们令 patch 间相互重叠，即以 stride 为 4 提取 8*8 的 patch，这样可使特征图的长宽增大一倍。

参考 datasetGAN 的方法，还需要引入多尺度信息，因此我们将同一张图像 resize 到不同尺寸再获取到不同尺度的特征，然后将这些不同尺度的特征上采样到相同的尺度，进行拼接，形成一个完整的多尺度特征。特征块每个 patch 对应的位置即是该 patch 对应的语义特征，维度为 8*8*6*n，其中 n 为多尺度数，这里我们选取 n=4，故我们得到的最终语义特征为 8*8*6*4=1536 维的向量。我们将这 1536 维的向量送入一个 3 层 MLP 进行分类，预测该 patch 所属的 label。至此我们完成了语义信息的标注。

五、实验分析与结论

我们使用了 partImageNet 数据集中的 5 个类别和 CoCo 数据集中的 2 个类别。部分实验效果如下：

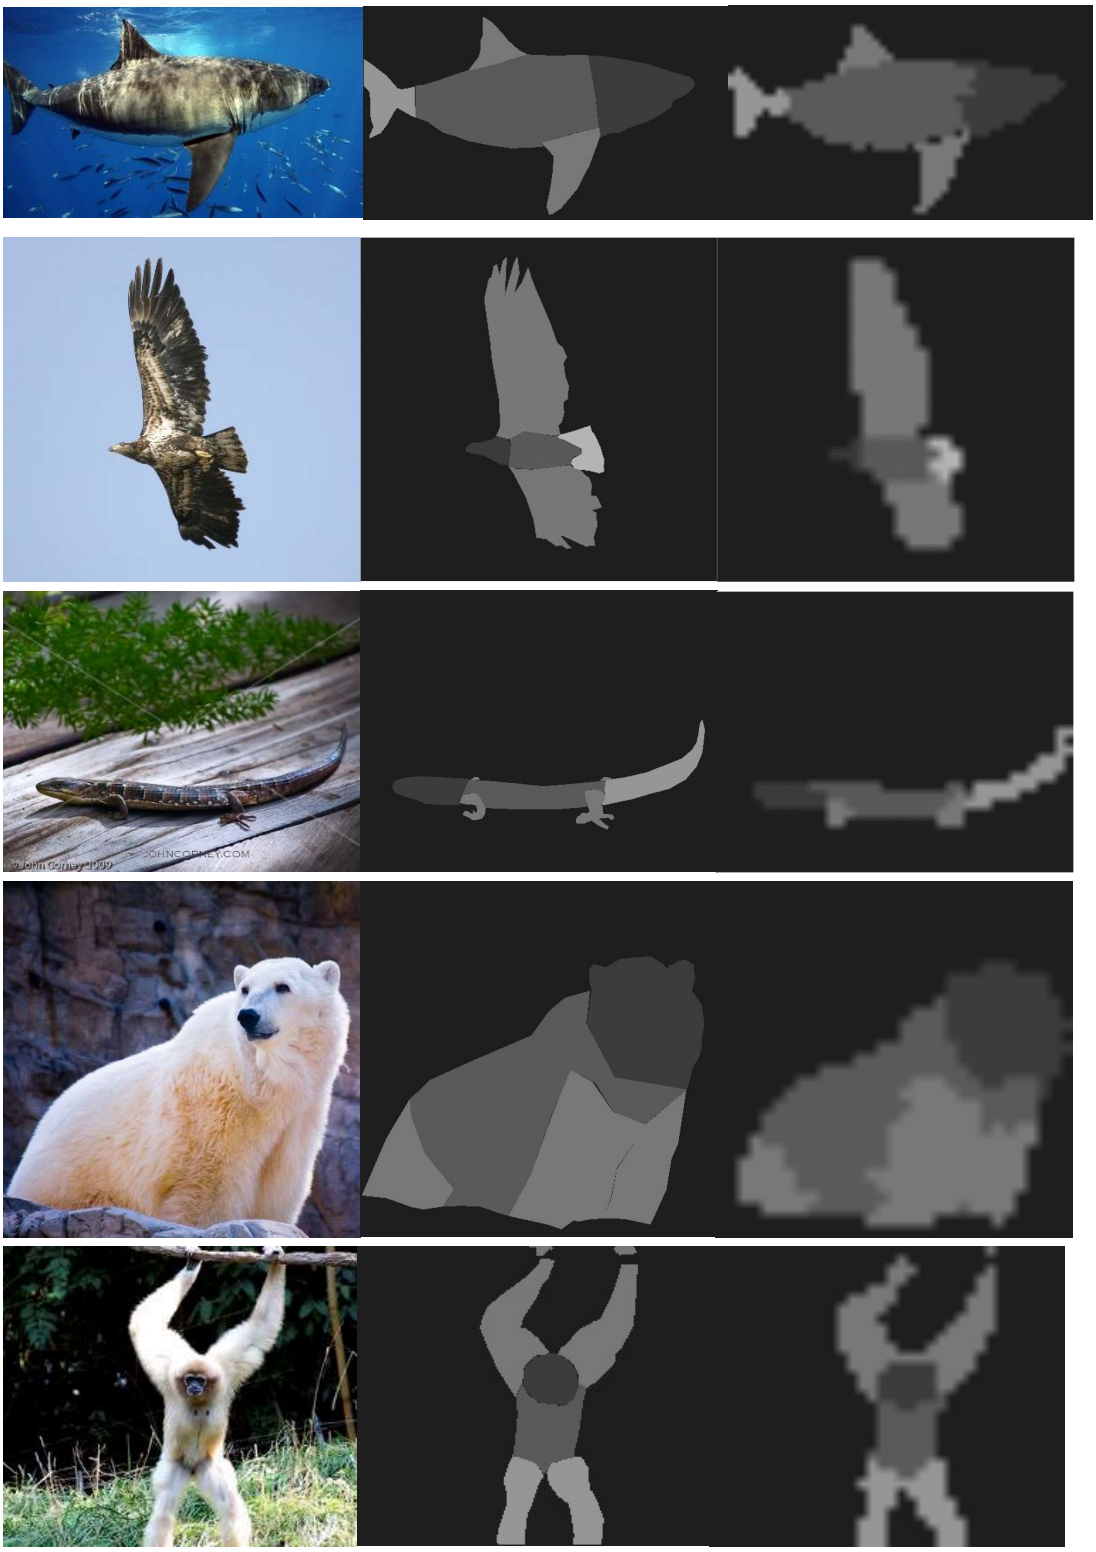

通过比较 ground truth 和我们生成的标签，计算得到

由于特征提取是 patch 的 stride 为 4，最终的预测结果分辨率会在原有最大尺度

的基础上除以 4。由于硬件条件的限制，DINO 可提取的最大分辨率为 128， 预测结果分辨率在 32 左右。因此将预测结果拉伸后像素化较为严重，我们在测试时将 ground truth 同样 resize 到与预测结果相同的低分辨率条件下，进行比对并计算准确率。在 partImageNet 上挑选的几个类的类中平均预测正确率最高 96.37%，最低 93.01%，综合各个类的平均预测正确率为 94.34%，在低分辨率下已经达到了不错水平，对于数据集标注信息来说已经达标。

可以合理推测，若硬件水平提高，特征提取分辨率可以增大到 512 或更高，那么预测正确率将达到更高水准。